

CONTRALORÍA GENERAL DE LA NACIÓN  
República de Colombia

INFORME DE PRUEBAS DE RENDIMIENTO  
Sistema de Auditoría Inteligente — SAI-CGN

IPR-SAI-CGN-001 | v1.0 | Fase de Pruebas — SAI-CGN

| Campo                | Detalle                                                |
|----------------------|--------------------------------------------------------|
| Proyecto             | Sistema de Auditoría Inteligente — SAI-CGN             |
| Código del documento | IPR-SAI-CGN-001                                        |
| Versión              | 1.0                                                    |
| Fecha de ejecución   | 13 al 17 de octubre de 2025                            |
| Fecha del informe    | 20 de octubre de 2025                                  |
| Herramientas usadas  | Apache JMeter 5.6 · Locust 2.x · Grafana + Prometheus  |
| Elaborado por        | QA Lead — Equipo SAI-CGN                               |
| Revisado por         | Mauricio Torres — Líder de Proyecto                    |
| Aprobado por         | Laura Rodríguez — Subdirectora de Sistemas CGN         |
| RNF verificados      | RNF-01, RNF-02, RNF-03, RNF-04, RNF-05, RNF-06, RNF-07 |
| Clasificación        | Documento Interno Restringido                          |

# 1. RESUMEN EJECUTIVO

Las pruebas de rendimiento del SAI-CGN fueron ejecutadas del 13 al 17 de octubre de 2025 sobre el ambiente de staging de la Contraloría General de la Nación. El objetivo fue verificar el cumplimiento de los SLA definidos en los RNF-01 al RNF-07 de la ERS v1.0 bajo condiciones de carga controlada equivalentes al uso real esperado en producción.

| RNF    | Descripción                               | Meta        | Resultado obtenido | Estado |
|--------|-------------------------------------------|-------------|--------------------|--------|
| RNF-01 | Tiempo de respuesta interfaz web (P95)    | < 3 seg     | 1.8 seg            | CUMPLE |
| RNF-02 | Motor IA: lote 100.000 registros          | < 10 min    | 7 min 42 seg       | CUMPLE |
| RNF-03 | Asistente RAG: respuesta (P95)            | < 5 seg     | 3.2 seg            | CUMPLE |
| RNF-04 | 200 usuarios concurrentes sin degradación | < 3 seg P95 | 2.6 seg            | CUMPLE |
| RNF-05 | Disponibilidad 99,5% horario laboral      | ≥ 99,5%     | 99,7%              | CUMPLE |
| RNF-06 | RTO (tiempo de recuperación ante fallo)   | ≤ 4 horas   | 2 h 15 min         | CUMPLE |
| RNF-07 | RPO (backups cada hora)                   | ≤ 1 hora    | Cada 55 minutos    | CUMPLE |

**CONCLUSIÓN EJECUTIVA:** El sistema SAI-CGN cumple el 100% de los requisitos no funcionales de rendimiento y disponibilidad establecidos en la ERS v1.0. El sistema está técnicamente habilitado para operar en producción desde la perspectiva del rendimiento.

2. AMBIENTE Y CONFIGURACIÓN DE PRUEBAS

2.1 Infraestructura del ambiente de staging

| Componente                 | Especificación                                                                 | Observaciones                                          |
|----------------------------|--------------------------------------------------------------------------------|--------------------------------------------------------|
| Servidor de aplicaciones   | 4 vCPU · 16 GB RAM · 500 GB SSD NVMe · Docker 24 + Kubernetes 1.28             | Réplica exacta del servidor de producción CGN          |
| Base de datos              | PostgreSQL 15.4 · 8 GB RAM · 200 GB SSD · AES-256 · Réplica lectura activa     | Cargada con 2.8 M de registros del dataset anonimizado |
| Servidor motor IA          | GPU NVIDIA A10G 24 GB · 16 vCPU · 64 GB RAM                                    | Modelos ML y LLM RAG desplegados localmente            |
| Servidor de carga (JMeter) | 8 vCPU · 32 GB RAM · Red 10 Gbps                                               | Aislado del servidor de aplicaciones                   |
| Balanceador de carga       | NGINX 1.25 — configurado para hasta 500 conexiones simultáneas                 | Misma configuración que producción                     |
| Monitoreo                  | Prometheus + Grafana · Alertas configuradas sobre CPU, RAM, latencia y errores | Dashboards en tiempo real durante todas las pruebas    |

2.2 Datos de prueba utilizados

| Dataset                | Volumen           | Fuente                         | Período            |
|------------------------|-------------------|--------------------------------|--------------------|
| Contratos SECOP II     | 1.2 M registros   | Sandbox SECOP II (anonimizado) | 2020 – 2024        |
| Presupuestos CHIP      | 850.000 registros | Sandbox CHIP (anonimizado)     | 2021 – 2024        |
| Auditorías históricas  | 12.500 registros  | Dataset CGN anonimizado        | 2022 – 2024        |
| Hallazgos fiscales     | 3.200 registros   | Dataset CGN anonimizado        | 2022 – 2024        |
| Corpus normativo (RAG) | 847 documentos    | Diario Oficial + SUIN-Juriscol | Vigente a oct 2025 |

3. ESCENARIOS DE PRUEBA EJECUTADOS

| ID Escenario | Descripción                                                    | Usuarios           | Duración | CP Relacionado |
|--------------|----------------------------------------------------------------|--------------------|----------|----------------|
| ESC-01       | Carga normal — navegación y consultas básicas                  | 50 concurrentes    | 30 min   | CP-R01         |
| ESC-02       | Carga pico — todas las funcionalidades activas simultáneamente | 200 concurrentes   | 30 min   | CP-R04         |
| ESC-03       | Análisis IA — lote máximo de 100.000 registros                 | 1 proceso batch    | < 15 min | CP-R02         |
| ESC-04       | Asistente RAG — consultas simultáneas de múltiples auditores   | 50 concurrentes    | 20 min   | CP-R03         |
| ESC-05       | Prueba de estrés — 300 usuarios (límite superior)              | 300 concurrentes   | 10 min   | CP-R04         |
| ESC-06       | Prueba de resistencia (soak test) — carga sostenida            | 150 concurrentes   | 4 horas  | CP-R05         |
| ESC-07       | Prueba de recuperación — fallo simulado del servidor principal | N/A (fallo manual) | —        | CP-R06         |
| ESC-08       | Verificación de backups automáticos en intervalos de 1 hora    | N/A (automatizado) | 2 horas  | CP-R07         |

4. RESULTADOS DETALLADOS POR ESCENARIO

4.1 ESC-01 — Carga normal (50 usuarios concurrentes)

| Transacción                    | Promedio (ms) | P50 (ms) | P90 (ms) | P95 (ms) | P99 (ms) | % Error | Meta P95           |
|--------------------------------|---------------|----------|----------|----------|----------|---------|--------------------|
| Login SSO                      | 320           | 310      | 390      | 420      | 580      | 0.0%    | < 3.000 ms         |
| Cargar dashboard de auditorías | 780           | 750      | 920      | 980      | 1.200    | 0.0%    | < 3.000 ms         |
| Buscar hallazgos               | 450           | 430      | 560      | 610      | 820      | 0.0%    | < 3.000 ms         |
| Consulta asistente RAG         | 2.100         | 2.050    | 2.800    | 3.100    | 3.800    | 0.0%    | < 5.000 ms         |
| Generar informe PDF            | 1.800         | 1.750    | 2.100    | 2.300    | 2.900    | 0.0%    | < 3.000 ms         |
| Cargar archivo CSV 50 MB       | 4.200         | 4.100    | 5.100    | 5.400    | 6.200    | 0.0%    | Sin SLA específico |

4.2 ESC-02 — Carga pico (200 usuarios concurrentes)

| Transacción                    | Promedio (ms) | P95 (ms) | % Error | CPU máx. | RAM máx. | Meta P95   |
|--------------------------------|---------------|----------|---------|----------|----------|------------|
| Login SSO                      | 510           | 780      | 0.02%   | 45%      | 52%      | < 3.000 ms |
| Cargar dashboard de auditorías | 1.150         | 1.820    | 0.01%   | 45%      | 52%      | < 3.000 ms |
| Buscar hallazgos               | 720           | 1.100    | 0.01%   | 45%      | 52%      | < 3.000 ms |
| Consulta asistente RAG         | 2.900         | 4.200    | 0.03%   | 72%      | 68%      | < 5.000 ms |
| Generar informe PDF            | 2.100         | 2.600    | 0.01%   | 45%      | 52%      | < 3.000 ms |
| PROMEDIO GENERAL               | 1.476         | 2.100    | 0.02%   | —        | —        | CUMPLE     |

Resultado ESC-02: Con 200 usuarios concurrentes el P95 general es de 2.1 seg, por debajo del umbral de 3 seg (RNF-01/RNF-04). La tasa de error es del 0.02%, muy por debajo del límite aceptable del 0.1%. CPU máxima en 72% (servidor motor IA durante consultas RAG simultáneas), dentro del rango aceptable.

4.3 ESC-03 — Motor IA: lote de 100.000 registros (RNF-02)

| Métrica                             | Resultado       | Meta                 | Estado      |
|-------------------------------------|-----------------|----------------------|-------------|
| Tiempo total de procesamiento       | 7 min 42 seg    | < 10 min             | CUMPLE      |
| Registros procesados por segundo    | 216 reg/seg     | Sin meta específica  | Informativo |
| Anomalías detectadas                | 1.847 hallazgos | Sin meta específica  | Informativo |
| Uso de GPU durante el procesamiento | 94% promedio    | Sin meta (máx. 100%) | Informativo |

| Métrica                  | Resultado       | Meta                 | Estado      |
|--------------------------|-----------------|----------------------|-------------|
| Uso de RAM GPU           | 21.2 GB / 24 GB | Sin meta (máx. 100%) | Informativo |
| Tasa de error del modelo | 0.0%            | 0%                   | CUMPLE      |

4.4 ESC-04 — Asistente RAG con 50 usuarios concurrentes (RNF-03)

| Métrica                           | Resultado | Meta    | Estado |
|-----------------------------------|-----------|---------|--------|
| Tiempo de respuesta P95           | 3.2 seg   | < 5 seg | CUMPLE |
| Tiempo de respuesta P99           | 4.1 seg   | < 5 seg | CUMPLE |
| Tiempo de respuesta máximo        | 4.8 seg   | < 5 seg | CUMPLE |
| Tasa de error                     | 0.0%      | < 0.1%  | CUMPLE |
| Precisión de respuestas (muestra) | 82%       | ≥ 80%   | CUMPLE |
| Respuestas con cita correcta      | 91%       | ≥ 80%   | CUMPLE |

4.5 ESC-05 — Prueba de estrés (300 usuarios — límite superior)

Esta prueba se ejecutó para identificar el punto de quiebre del sistema, no como requisito obligatorio.

| Métrica                   | Resultado           | Observación                                                                    |
|---------------------------|---------------------|--------------------------------------------------------------------------------|
| Tiempo de respuesta P95   | 4.2 seg             | Supera la meta de 3 seg — degradación perceptible pero sin caída del sistema   |
| Tasa de error             | 1.8%                | Supera el 0.1% aceptable — algunas consultas al RAG son rechazadas por timeout |
| Punto de quiebre estimado | ~260 usuarios       | El sistema mantiene SLA hasta aproximadamente 260 usuarios concurrentes        |
| Estado del sistema        | Estable (sin caída) | El sistema no colapsó; se degradó gradualmente                                 |

Observación ESC-05: El sistema supera los SLA con más de 260 usuarios. Dado que el requisito es 200 usuarios (RNF-04) y el sistema mantiene SLA hasta 260, existe un margen de seguridad del 30%. Se recomienda monitorear el crecimiento de usuarios en producción y planificar escalado horizontal cuando se supere el 70% de la capacidad máxima.

4.6 ESC-06 — Prueba de resistencia — 4 horas continuas (RNF-05)

| Métrica                    | Hora 1 | Hora 2 | Hora 3 | Hora 4 | Tendencia |
|----------------------------|--------|--------|--------|--------|-----------|
| P95 tiempo respuesta (seg) | 1.9    | 2.0    | 2.1    | 2.1    | Estable   |
| Tasa de error (%)          | 0.01   | 0.01   | 0.02   | 0.01   | Estable   |
| Uso CPU promedio (%)       | 41     | 43     | 44     | 43     | Estable   |
| Uso RAM promedio (%)       | 58     | 59     | 60     | 60     | Estable   |

| Métrica                 | Hora 1 | Hora 2 | Hora 3 | Hora 4 | Tendencia |
|-------------------------|--------|--------|--------|--------|-----------|
| Memory leaks detectados | 0      | 0      | 0      | 0      | Sin fugas |

4.7 ESC-07 — Prueba de recuperación ante fallo (RNF-06)

| Evento                                     | Hora     | Duración      | Meta     | Estado      |
|--------------------------------------------|----------|---------------|----------|-------------|
| Fallo simulado del servidor principal      | 10:00:00 | —             | —        | Activado    |
| Detección automática del fallo             | 10:00:47 | 47 seg        | < 5 min  | CUMPLE      |
| Inicio de la recuperación automática (k8s) | 10:01:02 | 75 seg        | < 5 min  | CUMPLE      |
| Sistema disponible parcialmente            | 10:15:30 | 15 min 30 seg | —        | Informativo |
| Sistema completamente restaurado (RTO)     | 12:15:00 | 2 h 15 min    | ≤ 4 h    | CUMPLE      |
| Último backup disponible antes del fallo   | 09:55:00 | 5 min antes   | RPO ≤ 1h | CUMPLE      |

4.8 ESC-08 — Verificación de backups automáticos (RNF-07)

| Backup             | Hora programada | Hora real de ejecución | Duración     | Tamaño           | Verificación     |
|--------------------|-----------------|------------------------|--------------|------------------|------------------|
| Backup 1           | 08:00           | 08:00:03               | 4 min 12 seg | 18.2 GB          | ÍNTEGRO          |
| Backup 2           | 09:00           | 09:00:02               | 4 min 08 seg | 18.3 GB          | ÍNTEGRO          |
| Backup 3           | 10:00           | 10:00:04               | 4 min 15 seg | 18.3 GB          | ÍNTEGRO          |
| Backup 4           | 11:00           | 11:00:01               | 4 min 09 seg | 18.4 GB          | ÍNTEGRO          |
| Intervalo promedio | 60 min          | 60 min 03 seg          | 4 min 11 seg | 18.3 GB promedio | CUMPLE<br>RNF-07 |

5. DEFECTOS Y OBSERVACIONES IDENTIFICADOS

| ID    | Descripción                                                                                                                                                       | Escenario | Severidad | Estado                                                                 |
|-------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------|-----------|-----------|------------------------------------------------------------------------|
| DR-01 | Las consultas simultáneas al asistente RAG (> 40 usuarios) incrementan la latencia P99 por encima de 4 seg. Causa: modelo LLM sin caché de respuestas frecuentes. | ESC-04    | Media     | Remediado — implementado caché de respuestas frecuentes                |
| DR-02 | Al generar más de 5 informes PDF simultáneamente, el tiempo de generación del P95 aumenta a 4.1 seg. Causa: generación sincrónica en el servidor principal.       | ESC-02    | Media     | Remediado — generación asíncrona con cola de trabajos                  |
| DR-03 | Con 300 usuarios (ESC-05) la tasa de error supera el 1%. Sistema fuera del SLA acordado.                                                                          | ESC-05    | Baja      | Aceptado — solo ocurre con 300 usuarios (50% más del requisito de 200) |



## 6. CONCLUSIONES Y RECOMENDACIONES

### 6.1 Conclusiones

---

- El sistema SAI-CGN cumple el 100% de los SLA de rendimiento definidos en los RNF-01 al RNF-07 de la ERS v1.0.
- Con 200 usuarios concurrentes (RNF-04) el P95 de tiempo de respuesta es de 2.1 seg, un 30% por debajo del límite de 3 seg.
- El motor de IA procesa 100.000 registros en 7 min 42 seg, 23% más rápido que el límite de 10 min (RNF-02).
- El asistente RAG responde consultas en 3.2 seg P95, 36% más rápido que el límite de 5 seg (RNF-03).
- El sistema se recuperó de un fallo simulado en 2 h 15 min, dentro del RTO de 4 horas (RNF-06).
- Los 2 defectos de severidad Media identificados fueron remediados y verificados antes de emitir este informe.

### 6.2 Recomendaciones para producción

---

1. Implementar alertas automáticas en Prometheus cuando la carga supere el 70% de la capacidad máxima ( $\approx$  140 usuarios concurrentes).
2. Planificar escalado horizontal (agregar un nodo adicional) cuando el número de usuarios activos supere los 180 de forma sostenida.
3. Ejecutar pruebas de rendimiento trimestrales en producción para detectar degradación por crecimiento de datos.
4. Revisar la capacidad del servidor GPU del motor IA en 6 meses; actualmente opera al 94% de GPU durante los análisis batch.

7. APROBACIÓN DEL INFORME

| Nombre y cargo                                 | Rol                           | Firma | Fecha    |
|------------------------------------------------|-------------------------------|-------|----------|
| QA Lead — Proveedor                            | Elaboró y ejecutó las pruebas | _____ | __/__/__ |
| Mauricio Torres — Líder de Proyecto            | Revisó                        | _____ | __/__/__ |
| Laura Rodríguez — Subdirectora de Sistemas CGN | Aprobó técnicamente           | _____ | __/__/__ |
| Carlos Martínez — Director de Control Fiscal   | Aprobó institucionalmente     | _____ | __/__/__ |